

周凯

Tel: 15995397689

Blog: <https://www.zhoukai.space>

意向城市: 上海、北京、南京、杭州

Email: kaizhou0305@gmail.com

Github: <https://github.com/zkforge>

意向岗位: 28 届日常实习 (3 个月)



教育经历 (Education)

吉林大学 (985)	硕士 人工智能学院 人工智能专业	吉林/长春	2025.9 - 2028.7
南京信息工程大学 (双一流)	本科 人工智能学院 数据科学与大数据技术专业	江苏/南京	2021.9 - 2025.7

项目经历 (Projects)

多模态专利文档智能问答 RAG 系统

项目负责人 | 2026 年 1 月 - 3 月

项目地址: <https://github.com/zkforge/ckks-multimodel-rag>

项目简介: 面向不可编辑工业技术 PDF 中图纸、表格、部件编号、页面位置关系和专利文本混合存在的开放问答任务, 构建从 MinerU 离线解析、页面证据渲染、文档内混合检索、规则路由、多模态生成到自动评测的端到端 RAG 系统。

技术栈: 解析: MinerU、PyMuPDF; 检索: Milvus、BM25、Rerank; 生成: LoRA、vLLM; 评测: EM、ROUGE、BERTScore

- 解析与证据构建:** 针对工业 PDF 不可编辑、图文混排、页码定位不稳定的问题, 接入 MinerU 进行离线结构化解析, 并基于 PyMuPDF 将显式页码问题渲染为页面图像证据; 采用页面级和段落级两阶段文本 chunk 切分策略, 构建包含文本、图像、位置关系和部件连接的多模态证据库。
- 规则路由:** 设计基于页码和关键词的规则路由 (空间关系、部件连接、流程图步骤、纯文本、通用视觉), 不同路由分别控制是否输入图片、检索深度和 prompt 约束, 使纯文本问题避免无效视觉输入, 图纸问题优先使用页面图像。提升整体回答准确率约 **8%**, 图纸题准确率提升约 **15%**, 并降低平均响应时间约 **30%**。
- 混合检索与重排:** 针对专利文本中型号、编号、参数和短字段仅靠语义检索容易漏召回的问题, 在 baseline 基础上引入 Qwen3-Embedding 与 Qwen3-Reranker 优化语义召回和精排效果, 并结合 BM25 稀疏检索补充关键词召回; 候选结果去重融合后输出 Top5, 提升细粒度事实和部件描述的上下文命中率约 **12%**。
- 微调生成与评测迭代:** 针对大模型回答过长、不确定表达和格式不稳定的问题, 封装 vLLM 调用本地 LoRA 微调后的 Qwen2.5-VL-32B, 加入短答案提示词约束、「空答案/不确定/过长回答」自动重试和答案清洗; 对比 Dense-only / 无路由 / 无重排消融基线, 最终在 3502 条测试集上按 BERTScore F1 / ROUGE-1 F1 / EM 加权评测综合得分达到 **0.6738**。

MedAgentCare: 面向多轮医疗咨询的多 Agent 协作与安全问答系统

项目负责人 | 2026 年 2 月 - 4 月

项目地址: <https://github.com/zkforge/MedAgentCare>

项目简介: 面向多症状、多轮次、信息不完整的医疗咨询场景, 构建“问诊信息采集 + 业务 Skill + 专业 Agent + Swarm 协作”的安全问答系统, 解决背景信息缺失、复杂问题拆解不足、上下文遗忘和安全边界不稳定的问题。

技术栈: 编排: ReAct、Swarm、Skills; 知识记忆: Milvus、Mem0; 前端: React、TypeScript; 服务: FastAPI、Docker

- 分层架构:** 针对医疗咨询能力在单一 Prompt 中难复用、约束的问题, 将检索、评估、建议和研究等能力拆分为 **9** 个业务 Skill; 定义路由 Agent、问诊 Agent 和 **3** 个 Worker Agent, 实现路由拆解、问诊采集与能力调用的职责解耦。
- 问诊路由:** 构建“信息采集 → 快速咨询 → Swarm 协作”的三路路由机制: 症状背景不足时由 InterviewAgent 逐轮追问关键信息并生成问诊摘要; 常见低风险咨询进入单 Agent 快速路径, 复杂问题由 LeadAgent 拆解后交给多个专业 Agent 并行处理; 智能路由准确率达 **95%**, 并相对 Swarm 基线将常见咨询延迟成本降低约 **75%**。
- 记忆机制:** 针对记忆历史的隐私问题, 实现短期会话历史、Mem0 长期记忆和本地文件记忆机制, 维护会话内最近 **5** 轮关键上下文, 支持跨会话相似案例检索; 多轮对话上下文理解准确率由 **60%** 提升至 **92%**。
- 安全约束与评测:** 通过 Harness Engineering 约束 Agent 能力边界、输出格式和安全策略, 覆盖免责声明、高危症状提醒、明确诊断和处方剂量风险, 并自动修复不合规输出; 在自建多轮医疗咨询样例集上结合 LLM-as-a-Judge 与人工抽检评估: 相比无问诊基线, 显著提升最终回答的完整性与稳定性。综合得分达到 **4.5/5**, 高于单 Agent 基线的 **3.8/5**。

技能 (Skills)

语言: CET4、CET6。

编程: 熟悉 Python、PyTorch、PostgreSQL、Redis, 能实现数据预处理、训练/微调、推理评测与数据读写流程。

大模型工程: 熟悉 RAG 检索链路、Agent 工具调用、多轮记忆、LoRA 微调、vLLM 推理部署与自动评测闭环。

工程化: 熟悉 FastAPI、Docker、Git、Linux, 具备本地服务化、前后端联调、缓存管理、评测脚本与日志排查能力。

工具: 具备高效的 AI 协同开发能力, 熟练利用 Claude Code / Codex 进行代码阅读、需求拆解、原型实现、问题排查。